


# Análise de padrões de consumo de filmes com K-Means e regras de associação



Autores: Daniel Teruel Fini e Matheus Chiqueto de Andrade



# O excesso de opções transformou o entretenimento em frustração.



O desafio de negócios das plataformas de streaming mudou. A guerra não é mais por adquirir novos títulos, mas por sugerir o filme certo para o usuário certo. Horas de navegação sem rumo destroem o engajamento e geram o abandono da plataforma.



# A mineração de dados revela a ordem oculta no comportamento do espectador.



## Foco: Tarefas Descritivas


Não estamos criando modelos preditivos para adivinhar o futuro. Estamos utilizando algoritmos para **extrair a realidade factual e os padrões comportamentais que já existem na base de usuários.**

# Duas abordagens complementares: K-Means e Apriori

|                                                                                                  |                                                                                                    |
|--------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------|
|  <b>K-Means</b> |  <b>Apriori</b> |
| Foco no Produto<br>(O Catálogo)                                                                  | Foco no Comportamento<br>(O Usuário)                                                               |
| Estruturação do Catálogo                                                                         | Recomendação ao Usuário                                                                            |
| Benefício: Mapear perfis de<br>popularidade baseados em notas e<br>volume.                       | Benefício: Descobrir padrões e<br>afinidades ocultas (o que é<br>assistido em conjunto).           |




# A engenharia de dados refina o ruído para extrair sinais verdadeiros.






# K-Means: Agrupando filmes por proximidade matemática.



**Fase 1**

O algoritmo distribui centróides aleatoriamente.



**Fase 2**

A distância Euclidiana de cada ponto até o centro é calculada.





**Fase 3**

Os centros se movem e se estabilizam, formando bairros de filmes com perfis idênticos.



# A escolha do 'K' ideal equilibra perfeição estatística e lógica de negócios.




## Por que K = 3?

O algoritmo apontou o pico em 4 grupos (Silhueta), mas a diferença estatística para 3 grupos era de irrelevantes 0.009. Com a curva de inércia apontando para o 3 (Cotovelo), optamos pela simplicidade: 3 divisões geram um catálogo muito mais limpo e fácil de interpretar.



# K-Means da base revela três perfis universais de popularidade.



## Cluster 0: O Mar do Nicho

A grande massa, pouco votada, notas dispersas. Independentes, antigos e obras desconhecidas.

## Cluster 1: O Prestígio Cult

Volume moderado de votos, mas notas altamente concentradas no topo. Os queridinhos da crítica.

## Cluster 2: Os Blockbusters

Elite do volume, o menor grupo em quantidade, mas com um absurdo número de avaliações. Campeões de bilheteria.



# Apriori: Mapeando a afinidade e a jornada do usuário.



A Regra de Ouro:

**SE (Gatilho)** → **ENTÃO (Resultado)**



## Filtro Severo de Qualidade

Apenas avaliações com Nota  $\geq 4.0$ .  
Transformamos avaliações contínuas em decisões puramente binárias (Gostou: Sim/Não).

### Análise Micro

Foco nos Títulos (limitado aos 200 filmes mais curtidos).

### Análise Macro

Foco nos Gêneros (324.391 usuários cruzados contra 19 gêneros puros).



# O painel de navegação para identificar regras matemáticas válidas.



Qual a porcentagem geral de usuários que assistiram ambos os itens juntos? É popular?



Dentre os que viram o filme A, qual a chance de verem o filme B? É provável?




Quantas vezes a probabilidade de consumir B aumenta graças a A? A regra é forte?  $Lift > 1.0$



# Resultados Micro: O algoritmo isola o fenômeno de maratona de franquias.

Resultado 1:



Resultado 8:



O top 10 das regras de títulos é inteiramente dominado por Senhor dos Anéis e Star Wars. O Apriori provou matematicamente o vínculo quase inquebrável de retenção: quem entra no funil de uma franquia de sucesso raramente abandona a jornada pela metade.



# Resultados Macro: A teia de gêneros e as preferências subconscientes.



## A Força do Drama

Em 9 das 10 principais regras, o Drama é o destino final.  
Exemplo: SE (Guerra) → ENTÃO (Drama) possui 99,8% de confiança.  
O Drama é a unanimidade do catálogo.

## A Dupla Perfeita

A regra SE (Mistério) → ENTÃO (Suspense) registrou o maior Lift da base (1.133) e uma confiança brutal de 98,1%.  
Uma transição quase garantida e uma recomendação sem erro.



# Impacto de Negócios: Vencendo o paradoxo da inicialização a frio.

Antes



**Cold Start.**

A plataforma não sabe nada sobre o cliente novo.  
Sugerir títulos aleatórios gera falhas imediatas.



Depois



**Engajamento Baseado em Gênero.**

Sugerir a dupla '**Mistério** e **Suspense**' no cadastro  
garante engajamento desde o clique zero.

O limite da análise focada apenas em títulos é o problema do 'Cold Start'.  
Porém, ao descobrir regras macros de gênero com confianças próximas de 99%, as  
plataformas podem aplicar combinações infalíveis logo no cadastro do usuário.



# O consumo de arte e entretenimento segue padrões lógicos absolutos.

Conseguimos ver na prática que esses dois algoritmos resolvem problemas diferentes e se completam: o K-Means organiza a retaguarda da plataforma (dividindo e segmentando o portfólio de filmes do catálogo), enquanto o Apriori é o motor ideal para a linha de frente (disparando recomendações inteligentes na tela para o usuário).