


Análise de padrões de **consumo de filmes** com **K-Means** e regras de associação



Autores: Daniel Teruel Fini e Matheus Chiqueto de Andrade

O excesso de opções transformou o entretenimento em frustração.



O desafio de negócios das plataformas de streaming mudou. A guerra não é mais por adquirir novos títulos, mas por sugerir o filme certo para o usuário certo. Horas de navegação sem rumo destroem o engajamento e geram o abandono da plataforma.


A mineração de dados revela a ordem oculta no comportamento do espectador.



Foco: Tarefas Descritivas

Não estamos criando modelos preditivos para adivinhar o futuro. Estamos utilizando algoritmos para **extrair a realidade factual e os padrões comportamentais que já existem na base de usuários.**


A engenharia de dados refina o ruído para extrair sinais verdadeiros.



Duas abordagens complementares: K-Means e Apriori


 K-Means	 Apriori
Foco nos filmes (agrupamento)	Foco no comportamento (associação)
Estruturação da base de dados	Análise de padrões
Benefício: Mapear perfis de popularidade baseados em notas e volume.	Benefício: Descobrir padrões e afinidades ocultas (o que é assistido em conjunto).

K-Means: Agrupando filmes por proximidade matemática.



Fase 1

O algoritmo distribui centróides aleatoriamente.



Fase 2



A distância Euclidiana de cada ponto até o centro é calculada.



Fase 3

Os centros se movem e se estabilizam, formando bairros de filmes com perfis idênticos.


A escolha do 'K' ideal equilibra perfeição estatística e lógica de negócios.



Por que K = 3?

O algoritmo apontou o pico em 4 grupos (Silhueta), mas a diferença estatística para 3 grupos era de irrelevantes 0.009. Com a curva de inércia apontando para o 3 (Cotovelo), optamos pela simplicidade: 3 divisões gerando uma divisão de filmes em grupos mais limpa e fácil de interpretar.

K-Means da base revela três perfis universais de popularidade.



Cluster 0: O Mar do Nicho

A grande massa, pouco votada, notas dispersas. Independentes, antigos e obras desconhecidas.

Cluster 1: O Prestígio Cult

Volume moderado de votos, mas notas altamente concentradas no topo. Os queridinhos da crítica.

Cluster 2: Os Blockbusters

Elite do volume, o menor grupo em quantidade, mas com um absurdo número de avaliações. Campeões de bilheteria.

Apriori: Mapeando a afinidade e a jornada do usuário.



A Regra de Ouro:

SE (Gatilho) → **ENTÃO (Resultado)**



Filtro Severo de Qualidade

Apenas avaliações com Nota ≥ 4.0 .
Transformamos avaliações contínuas em decisões puramente binárias (Gostou: Sim/Não).

Análise Micro

Foco nos Títulos (limitado aos 200 filmes mais curtidos).

Análise Macro

Foco nos Gêneros (324.391 usuários cruzados contra 19 gêneros puros).

O painel de navegação para identificar regras matemáticas válidas.



Qual a porcentagem geral de usuários que assistiram ambos os itens juntos? É popular?




Dentre os que viram o filme A, qual a chance de verem o filme B? É provável?



Quantas vezes a probabilidade de consumir B aumenta graças a A? A regra é forte? $Lift > 1.0$

Resultados Micro: O algoritmo isola o fenômeno de maratona de franquias.

Resultado 1:



Resultado 8:



O top 10 das regras de títulos é inteiramente dominado por Senhor dos Anéis e Star Wars. O Apriori provou matematicamente o vínculo quase inquebrável de retenção: quem entra no funil de uma franquia de sucesso raramente abandona a jornada pela metade.

Resultados Macro: A teia de gêneros e as preferências subconscientes.



A Força do Drama

Em 9 das 10 principais regras, o Drama é o destino final.
Exemplo: SE (Guerra) → ENTÃO (Drama) possui 99,8% de confiança.
O Drama é a unanimidade do catálogo.

A Dupla Perfeita

A regra SE (Mistério) → ENTÃO (Suspense) registrou o maior Lift da base (1.133) e uma confiança brutal de 98,1%.
Uma transição quase garantida e uma recomendação sem erro.

Impacto de Negócios: Vencendo o paradoxo da inicialização a frio.

Antes



Cold Start.

A plataforma não sabe nada sobre o cliente novo.
Sugerir títulos aleatórios gera falhas imediatas.



Depois



Engajamento Baseado em Gênero.

Sugerir a dupla '**Mistério** e **Suspense**' no cadastro
garante engajamento desde o clique zero.

O limite da análise focada apenas em títulos é o problema do 'Cold Start'.
Porém, ao descobrir regras macros de gênero com confianças próximas de 99%, as
plataformas podem aplicar combinações infalíveis logo no cadastro do usuário.

O consumo de arte e entretenimento segue padrões lógicos absolutos.

Conseguimos ver na prática que esses dois algoritmos resolvem problemas diferentes e se completam: o K-Means organiza e estrutura a base de dados (dividindo e segmentando os filmes), enquanto o Apriori é o motor ideal para análise de padrões ocultos e reais da base (gerando regras e recomendações inteligentes para o usuário).