

Análise de padrões de consumo de filmes com K-Means e regras de associação

Autores:

Daniel Teruel Fini e Matheus de Andrade Chiquetto

INTRODUÇÃO

Hoje em dia, com o crescimento gigantesco das plataformas de streaming e a digitalização do cinema, o que não falta é opção de filme para assistir. O grande problema das plataformas atuais mudou: o desafio não é mais conseguir novos títulos para o catálogo, mas sim conseguir sugerir o filme certo para o usuário certo, evitando que ele perca horas navegando sem rumo pela tela inicial.

É aí que entra a Mineração de Dados. Ela funciona como uma ferramenta essencial para vasculhar montanhas de dados e extrair padrões de comportamento que estavam escondidos.

Este projeto foi desenvolvido para aplicar duas técnicas descritivas em uma base de dados de cinema, focando em dois grandes objetivos:

- Organizar os filmes do catálogo em grupos (os chamados *clusters*) baseando-se em como o público reage a eles (sua nota média e a quantidade de votos que receberam). Isso ajuda a separar automaticamente os grandes sucessos de bilheteria daqueles filmes mais de nicho ou *cult*.
- Descobrir regras de associação para entender a jornada do usuário, revelando quais filmes ou gêneros costumam ser assistidos juntos. A ideia é criar uma base lógica e sólida para turbinar os motores de recomendação dessas plataformas.

JUSTIFICATIVA

Estudar esse comportamento faz todo sentido no mercado atual de entretenimento. Quando uma plataforma entende o perfil do seu catálogo e como os clientes combinam suas escolhas, ela consegue prender a atenção do usuário por mais tempo, diminui os cancelamentos de assinaturas (o famoso *churn*) e gasta o dinheiro de forma muito mais inteligente na hora de comprar os direitos de novos filmes.

Para o nosso grupo, o projeto foi uma oportunidade incrível de sair da teoria e aplicar o aprendizado de máquina não supervisionado em um cenário do mundo real. Lidar com uma base de dados massiva nos desafiou a pensar além das fórmulas, exigindo técnicas de engenharia de dados e otimização de código para que o computador aguentasse rodar os algoritmos sem travar a memória RAM.

REVISÃO DA LITERATURA

A Mineração de Dados faz parte de um processo maior chamado KDD (descoberta de conhecimento em bases de dados), que cuida de tudo: desde a limpeza dos dados brutos até a hora em que interpretamos os resultados finais. Na matéria, aprendemos que existem tarefas preditivas (que tentam adivinhar um valor futuro, como a classificação e a regressão) e tarefas descritivas (que buscam explicar o que já está acontecendo nos dados, como o agrupamento e a associação). Este trabalho foca inteiramente nas tarefas descritivas.

Agrupamento de Dados (Clustering)

Agrupar dados significa pegar um monte de informações misturadas e dividi-las em pedaços. A regra de ouro aqui é fazer com que os elementos que ficaram dentro do mesmo grupo sejam muito parecidos entre si, e que os grupos sejam bem diferentes uns dos outros.

O algoritmo escolhido para essa missão foi o K-Means. Ele funciona de forma iterativa: o algoritmo chuta centros para os grupos (centróides), calcula a distância euclidiana de cada dado até esses centros para ver quem fica onde, e depois

recalcula a posição desses centros tirando a média dos pontos, repetindo até os grupos se estabilizarem.

Para descobrir matematicamente quantos grupos fazer (K), usamos duas técnicas:

- **Método do Cotovelo:** Plota um gráfico da chamada Inércia (que mede a distância dos pontos até o centro do seu grupo). Conforme aumentamos o número de grupos, essa distância cai. Nós procuramos o ponto onde a curva dobra de forma acentuada (o "cotovelo"), mostrando que criar mais grupos a partir dali não trará ganho real.
- **Coeficiente de Silhueta Médio:** É uma métrica que dá uma nota de -1 a 1 para o agrupamento. Ela analisa a coesão (se os pontos estão pertinho dentro do grupo) e a separação (se os grupos estão bem longe uns dos outros). Quanto mais perto de 1, melhor ficou a divisão.

Regras de Associação

Essa técnica serve para encontrar regras de afinidade do tipo "quem compra X, também compra Y", muito conhecida no mercado como análise de cesta de compras. A estrutura de uma regra é sempre uma implicação lógica: SE (A) → ENTÃO (B), onde A é o gatilho (antecedente) e B é o resultado (consequente).

O algoritmo utilizado foi o Apriori, que faz uma busca inteligente para mapear os itens que aparecem juntos com frequência. Para saber se uma regra é boa de verdade, olhamos para três números:

- **Suporte (Support):** Representa a proporção ou porcentagem de usuários na base de dados que assistiram (ou avaliaram) ambos os itens juntos. Indica a frequência com que o conjunto de filmes aparece no histórico geral de consumo.
- **Confiança (Confidence):** É a taxa de acerto da regra. Indica a porcentagem de usuários que, dentre os que assistiram ao filme A, também consumiram o filme B. É a probabilidade de o espectador assistir ao segundo título após ter visto o primeiro.

- **Lift:** Mede a força e a relevância estatística da regra. Indica quantas vezes a probabilidade de consumir o item B aumenta quando o item A já foi consumido. Se o $Lift > 1.0$, a regra possui uma associação positiva e é válida para recomendação.

METODOLOGIA E RESULTADOS

Base de Dados

Trabalhamos com a base de dados MovieLens, referência mundial em estudos de recomendação, criada pela GroupLens Research na Universidade de Minnesota. Baixamos os dados direto da plataforma deles, divididos em dois arquivos:

- **movies.csv:** Onde ficam o código do filme (movieId), o título com o ano de lançamento (title) e os gêneros dele grudados por uma barra em pé (genres, ex: Action|Sci-Fi).
- **ratings.csv:** Onde fica o histórico bruto das avaliações dos usuários. Tem o código do usuário (userId), o código do filme (movieId), a nota que ele deu (rating, que vai de 0.5 a 5.0) e o momento da avaliação (timestamp, que descartamos por não fazer sentido para os nossos algoritmos).

A primeira coisa que realizamos foi uma limpeza padrão: usamos o comando `.dropna()` para retirar fora qualquer linha que estivesse sem o ID do filme ou do usuário, limpando a base, obtendo um total de 43.873 filmes.

Agrupamento de Dados

Objetivo da análise

A nossa meta aqui era categorizar o catálogo de filmes automaticamente, criando perfis de popularidade baseados na opinião do público.

Dados utilizados

Pegamos a tabela de avaliações e agrupamos por filme para extrair duas informações contínuas: a nota média de cada título e o total de votos que ele recebeu. Depois, juntamos essas colunas novas com a tabela de nomes de filmes usando cruzamento interno (merge).


Técnicas de pré-processamento aplicadas

- **Filtro de corte de votos:** Só deixamos no modelo os filmes que tinham recebido pelo menos 5 votos. *Justificativa:* Filmes pouquíssimo conhecidos (com 1 ou 2 votos) costumam ter notas distorcidas. Se um usuário isolado der nota 5.0 para um filme desconhecido, a média dele vai para o topo de forma injusta, criando anomalias (*outliers*) que prejudicam o cálculo de distância do K-Means.
- **Padronização Z-Score (StandardScaler):** Aplicamos essa transformação nas notas e nos votos. *Justificativa:* O volume de votos chega a milhares, enquanto as notas variam só de 0.5 a 5.0. Se jogássemos esses valores brutos no algoritmo, a distância dos votos esmagaria a das notas, tornando a avaliação do filme invisível para o modelo. A padronização deixa as duas variáveis com o mesmo peso.

Algoritmo escolhido e critério de definição do número de grupos

Rodamos o K-Means testando opções de 2 a 10 grupos. Para não travar o computador ao calcular a Silhueta na base inteira, usamos uma amostra segura de 5.000 registros.


Ao analisar os gráficos gerados, observamos um cenário interessante: o Coeficiente de Silhueta apresentou o seu pico máximo absoluto em $K = 4$ (0.536), seguido de $K = 3$ (0.527). No entanto, o gráfico do Método do Cotovelo revelou que a descida da curva de Inércia se estabiliza de forma acentuada logo após o 3. Como a diferença matemática no score de Silhueta entre os dois valores é irrelevante (apenas 0,009) e o "cotovelo" da Inércia apontou para o 3, adotamos estrategicamente $K = 3$. Essa decisão une a consistência estatística dos dois gráficos à busca por simplicidade, gerando uma divisão de catálogo muito mais limpa e interpretável para as regras.



Avaliação dos resultados obtidos

Ao rodar o modelo definitivo com 3 grupos e desfazer a padronização dos centróides (`inverse_transform`), conseguimos traçar o perfil exato do catálogo:

- **Cluster 0 (filmes de nicho / pouco votados):** Tem pouquíssimos votos e notas bem espalhadas. É a grande massa do catálogo, formada por filmes independentes, antigos ou desconhecidos do grande público.
- **Cluster 1 (filmes cult / aclamados):** Tem um volume médio/alto de votos e notas muito boas. É a prateleira dos filmes de prestígio, queridos pela crítica e por cinéfilos dedicados.
- **Cluster 2 (blockbusters de massa):** É o menor grupo em quantidade de filmes, mas tem um volume absurdo de votos. São os campeões de bilheteria, filmes super populares que quase todo mundo assiste e avalia.



Regras de Associação

Objetivo da análise

Aqui o foco mudou para o comportamento do usuário. Queríamos entender dois níveis de consumo: o micro (quais filmes específicos andam juntos) e o macro (como os gostos por gêneros se cruzam na cabeça das pessoas).

Dados utilizados e pré-processamento

Para as duas análises, aplicamos um filtro de corte bem severo: só consideramos avaliações com nota maior ou igual a 4.0. *Justificativa:* Precisávamos mapear o que o usuário realmente gostou (relevância de mercado), transformando notas contínuas em uma "cesta de compras" booleana (verdadeiro se gostou, falso se não assistiu ou não gostou).

- **Preparação por títulos (foco no produto):** Criar uma matriz com todos os filmes causaria um estouro de memória no computador. Por isso, filtramos o escopo mantendo apenas os 200 filmes mais curtidos da base. Agrupamos por usuário, pivotamos a tabela e binarizamos tudo de forma direta e rápida

usando o operador lógico (matriz > 0), resultando em uma matriz final de 283.514 usuários por 200 filmes.

- **Preparação por gêneros (foco no perfil):** Aqui processamos todos os 324.391 usuários da base. Para a memória aguentar, agrupamos os gêneros por usuário, limpamos o termo genérico (no genres listed) e usamos o método .explode() para abrir as listas de forma vetorizada. No fim, geramos uma matriz enxuta de 19 colunas puras (os gêneros reais da base), binarizada com o operador lógico (matriz > 0).

Algoritmo empregado e apresentação das principais regras

Usamos o algoritmo Apriori da biblioteca mlxtend e organizamos o ranking final de regras de forma decrescente pela coluna de confiança.

Principais regras por título (suporte maior ou igual a 0.15 | confiança maior ou igual a 0.50)

Posição	Filme Antecedente (SE...)	Filme Consequente (... ENTÃO)	Suporte	Confiança	Lift
1º	Lord of the Rings: The Two Towers, The (2002)	Lord of the Rings: The Return of the King, The (2003)	0.162	0.838	4.198
2º	Lord of the Rings: The Return of the King, The (2003)	Lord of the Rings: The Two Towers, The (2002)	0.162	0.810	4.198
3º	Lord of the Rings: The Two Towers, The (2002)	Lord of the Rings: The Fellowship of the Ring, The (2001)	0.166	0.862	4.081
4º	Lord of the Rings: The Fellowship of the Ring, The (2001)	Lord of the Rings: The Two Towers, The (2002)	0.166	0.787	4.081
5º	Lord of the Rings: The Return of the King, The (2003)	Lord of the Rings: The Fellowship of the Ring, The (2001)	0.167	0.835	3.953

6º	Lord of the Rings: The Fellowship of the Ring, The (2001)	Lord of the Rings: The Return of the King, The (2003)	0.167	0.789	3.953
7º	Star Wars: Episode V - The Empire Strikes Back (1980)	Star Wars: Episode IV - A New Hope (1977)	0.175	0.809	3.153
8º	Star Wars: Episode IV - A New Hope (1977)	Star Wars: Episode V - The Empire Strikes Back (1980)	0.175	0.680	3.153
9º	Star Wars: Episode VI - Return of the Jedi (1983)	Star Wars: Episode IV - A New Hope (1977)	0.152	0.795	3.098
10º	Star Wars: Episode IV - A New Hope (1977)	Star Wars: Episode VI - Return of the Jedi (1983)	0.152	0.592	3.098

Os resultados mostraram que o algoritmo isolou perfeitamente o comportamento de maratona de franquias. Quem começa a assistir a uma sequência dificilmente para na metade. Um exemplo claro que saiu no topo dos nossos resultados foi:

- SE (The Lord of the Rings: The Two Towers) → ENTÃO (The Lord of the Rings: The Fellowship of the Ring). Essa regra veio com um suporte alto, confiança superior a 85% e um Lift > 4.0, provando matematicamente o forte vínculo desse nicho de fãs.

Principais regras por gênero (suporte maior ou igual a 0.60 | confiança maior ou igual a 0.60)

Como os gêneros são muito comuns, o algoritmo encontrou inicialmente um total de 5.372 associações. Para refinar esse resultado, filtramos a base para exibir apenas regras puras (com 1 gênero por vez) e com Lift > 1.0, reduzindo o escopo para as 94 regras mais relevantes.

Posição	Gênero Antecedente (SE...)	Gênero Consequente (... ENTÃO)	Suporte	Confiança	Lift
---------	----------------------------	--------------------------------	---------	-----------	------

1º	War	Drama	0.637	0.998	1.045
2º	Mystery	Drama	0.662	0.990	1.037
3º	Crime	Drama	0.813	0.987	1.034
4º	Romance	Drama	0.806	0.985	1.032
5º	Mystery	Thriller	0.656	0.981	1.133
6º	Fantasy	Drama	0.684	0.980	1.027
7º	Thriller	Drama	0.844	0.975	1.022
8º	Sci-Fi	Drama	0.752	0.970	1.016
9º	Comedy	Drama	0.867	0.969	1.015
10º	Adventure	Drama	0.817	0.967	1.013

Desse grupo selecionado, o Top 10 trouxe duas grandes descobertas sobre o perfil dos usuários:

- **A força do gênero Drama:** Em 9 das 10 principais regras do ranking, o resultado final (consequente) foi o gênero Drama. A regra SE (War) → ENTÃO (Drama), por exemplo, trouxe uma confiança impressionante de 99,8% (suporte: 0.637; lift: 1.045). Isso prova que quem consome gêneros mais específicos (como Guerra ou Histórico) quase inevitavelmente consome e gosta de dramas, mostrando que esse gênero é uma unanimidade na base.
- **A dupla perfeita:** A regra SE (Mystery) → ENTÃO (Thriller) registrou suporte de 0.656 (65,6%), confiança de 0.981 (98,1%) e o maior Lift do nosso ranking (1.133). Isso indica uma preferência muito direcionada: quem gosta de tramas de Mistério tem uma inclinação real e exclusiva ao consumo de Suspense.

CONCLUSÃO

A modelagem descritiva funcionou perfeitamente. Conseguimos ver na prática que esses dois algoritmos resolvem problemas diferentes e se completam: o K-Means é ótimo para organizar a retaguarda da plataforma (dividindo e segmentando o portfólio de filmes do catálogo), enquanto o Apriori é o motor ideal

para a linha de frente (disparando recomendações inteligentes na tela para o usuário).

Fazendo uma análise crítica do desenvolvimento, o limite de 200 filmes foi um passo obrigatório para não travar o hardware na associação por títulos. Em contrapartida, a nossa estratégia na modelagem por gêneros usando o método `.explode()`, contornou o volume gigante de mais de 324 mil usuários e condensou tudo em uma matriz leve de 19 colunas.

Os resultados que encontramos batem muito de perto com o que vemos no mercado de tecnologia atual e em artigos publicados pela Netflix ou pelo MovieLens. Estudos da área de sistemas de recomendação mostram que sugerir coisas baseando-se apenas em títulos sofre com o problema de "inicialização a frio" (*cold start*), que é quando um usuário acabou de criar a conta e a plataforma ainda não sabe o que ele curte. A descoberta de regras macros de gênero com confianças batendo em quase 99% valida o que as grandes plataformas fazem na prática: sugerir gêneros interligados e de apelo universal logo no cadastro do cliente, garantindo que ele ache algo de valor e continue engajado desde o primeiro clique.

REFERÊNCIAS

GODOY, Angela Rosa Locateli de. **Mineração de Dados**. Rio Claro: FATEC, 2026.

HARPER, F. Maxwell; KONSTAN, Joseph A. **The MovieLens Datasets: History and Context**. ACM Transactions on Interactive Intelligent Systems (TiIS), v. 5, n. 4, p. 1-19, 2015.

NIELSEN. **Nielsen's State of Play report reveals that streaming is the future, but consumers are currently overwhelmed by choice**. Nielsen Insights, 2023.

Disponível em:

<https://www.nielsen.com/news-center/2022/nielsens-state-of-play-report-reveals-that-streaming-is-the-future-but-consumers-are-currently-overwhelmed-by-choice/>.

Acesso em: 21 maio 2026.

NIELSEN. **Nielsen's State of Play Report Delivers New Insights as Streaming's Next Evolution Brings Content Discovery Challenges for Viewers.** Nielsen

Insights, 2022. Disponível em:

<https://www.nielsen.com/news-center/2023/nielsens-state-of-play-report-delivers-new-insights-as-streamings-next-evolution-brings-content-discovery-challenges-for-viewers/>. Acesso em: 21 maio 2026.

TECMUNDO. **Pesquisa revela tempo médio dos assinantes para escolher programas em streaming.** Portal TecMundo, Minha Série, 2019. Disponível em:

<https://www.tecmundo.com.br/minha-serie/160144-pesquisa-revela-tempo-medio-dos-assinantes-para-escolher-programas-em-streaming.html>. Acesso em: 22 maio 2026.