

Análise de padrões de consumo de filmes com K-Means e regras de associação

Autores:

Daniel Teruel Fini e Matheus de Andrade Chiquetto

INTRODUÇÃO

Hoje em dia, com o crescimento gigantesco das plataformas de streaming e a digitalização do cinema, o que não falta é opção de filme para assistir. O grande problema das plataformas atuais mudou: o desafio não é mais conseguir novos títulos para o catálogo, mas sim conseguir sugerir o filme certo para o usuário certo, evitando que ele perca horas navegando sem rumo pela tela inicial.

É aí que entra a Mineração de Dados. Ela funciona como uma ferramenta essencial para vasculhar montanhas de dados e extrair padrões de comportamento que estavam escondidos.

Este projeto foi desenvolvido para aplicar duas técnicas descritivas em uma base de dados de cinema, focando em dois grandes objetivos:

- Organizar os filmes do catálogo em grupos (os chamados *clusters*) baseando-se em como o público reage a eles (sua nota média e a quantidade de votos que receberam). Isso ajuda a separar automaticamente os grandes sucessos de bilheteria daqueles filmes mais de nicho ou *cult*.
- Descobrir regras de associação para entender a jornada do usuário, revelando quais filmes ou gêneros costumam ser assistidos juntos. A ideia é criar uma base lógica e sólida para turbinar os motores de recomendação dessas plataformas.

JUSTIFICATIVA

Estudar esse comportamento faz todo sentido no mercado atual de entretenimento. Quando uma plataforma entende o perfil do seu catálogo e como os clientes combinam suas escolhas, ela consegue prender a atenção do usuário por mais tempo, diminui os cancelamentos de assinaturas (o famoso *churn*) e gasta o dinheiro de forma muito mais inteligente na hora de comprar os direitos de novos filmes.

Para o nosso grupo, o projeto foi uma oportunidade incrível de sair da teoria e aplicar o aprendizado de máquina não supervisionado em um cenário do mundo real. Lidar com uma base de dados massiva nos desafiou a pensar além das fórmulas, exigindo técnicas de engenharia de dados e otimização de código para que o computador aguentasse rodar os algoritmos sem travar a memória.

REVISÃO DA LITERATURA

A Mineração de Dados faz parte de um processo maior chamado KDD (descoberta de conhecimento em bases de dados), que cuida de tudo: desde a limpeza dos dados brutos até a hora em que interpretamos os resultados finais. Na matéria, aprendemos que existem tarefas preditivas (que tentam adivinhar um valor futuro, como a classificação e a regressão) e tarefas descritivas (que buscam explicar o que já está acontecendo nos dados, como o agrupamento e a associação). Este trabalho foca inteiramente nas tarefas descritivas.

Agrupamento de Dados (Clustering)

Agrupar dados significa pegar um monte de informações misturadas e dividi-las em pedaços. A regra de ouro aqui é fazer com que os elementos que ficaram dentro do mesmo grupo sejam muito parecidos entre si, e que os grupos sejam bem diferentes uns dos outros.

O algoritmo escolhido para essa missão foi o K-Means. Ele funciona de forma iterativa: o algoritmo chuta centros para os grupos (centróides), calcula a distância euclidiana de cada dado até esses centros para ver quem fica onde, e depois recalcula a posição desses centros tirando a média dos pontos, repetindo até os grupos se estabilizarem.

Para descobrir matematicamente quantos grupos fazer (K), usamos duas técnicas:

- **Método do Cotovelo:** Plota um gráfico da chamada Inércia (que mede a distância dos pontos até o centro do seu grupo). Conforme aumentamos o número de grupos, essa distância cai. Nós procuramos o ponto onde a curva dobra de forma acentuada (o "cotovelo"), mostrando que criar mais grupos a partir dali não trará ganho real.
- **Coefficiente de Silhueta Médio:** É uma métrica que dá uma nota de -1 a 1 para o agrupamento. Ela analisa a coesão (se os pontos estão pertinho dentro do grupo) e a separação (se os grupos estão bem longe uns dos outros). Quanto mais perto de 1, melhor ficou a divisão.

Regras de Associação

Essa técnica serve para encontrar regras de afinidade do tipo "quem compra X, também compra Y", muito conhecida no mercado como análise de cesta de compras. A estrutura de uma regra é sempre uma implicação lógica: SE (A) -> ENTÃO (B), onde A é o gatilho (antecedente) e B é o resultado (consequente).

O algoritmo utilizado foi o Apriori, que faz uma busca inteligente para mapear os itens que aparecem juntos com frequência. Para saber se uma regra é boa de verdade, olhamos para três números:

- **Suporte (Support):** É a porcentagem de transações da base inteira que têm os dois itens juntos.
- **Confiança (Confidence):** É a taxa de acerto da regra. Mostra, de todas as pessoas que pegaram o item A, qual a porcentagem delas que também levou o item B.
- **Lift:** É o fator de empurrão. Ele mede quantas vezes a chance de consumir o item B aumenta quando sabemos que a pessoa consumiu o A, tirando o efeito do acaso. Se o Lift > 1.0, a regra tem uma associação positiva e é útil para fazermos recomendações.

METODOLOGIA E RESULTADOS

Base de Dados

Trabalhamos com a base de dados MovieLens, referência mundial em estudos de recomendação, criada pela GroupLens Research na Universidade de Minnesota. Baixamos os dados direto da plataforma deles, divididos em dois arquivos:

- **movies.csv:** Onde ficam o código do filme (movieId), o título com o ano de lançamento (title) e os gêneros dele grudados por uma barra em pé (genres, ex: Action|Sci-Fi).
- **ratings.csv:** Onde fica o histórico bruto das avaliações dos usuários. Tem o código do usuário (userId), o código do filme (movieId), a nota que ele deu (rating, que vai de 0.5 a 5.0) e o momento da avaliação (timestamp, que descartamos por não fazer sentido para os nossos algoritmos).

A primeira coisa que realizamos foi uma limpeza padrão: usamos o comando `.dropna()` para retirar fora qualquer linha que estivesse sem o ID do filme ou do usuário, limpando a base, obtendo uma base de 43.873 filmes.

.

Agrupamento de Dados

Objetivo da análise

A nossa meta aqui era categorizar o catálogo de filmes automaticamente, criando perfis de popularidade baseados na opinião do público.

Dados utilizados

Pegamos a tabela de avaliações e agrupamos por filme para extrair duas informações contínuas: a nota média de cada título e o total de votos que ele recebeu. Depois, juntamos essas colunas novas com a tabela de nomes de filmes usando cruzamento interno (merge).


Técnicas de pré-processamento aplicadas

- **Filtro de corte de votos:** Só deixamos no modelo os filmes que tinham recebido pelo menos 5 votos. *Justificativa:* Filmes pouquíssimo conhecidos (com 1 ou 2 votos) costumam ter notas distorcidas. Se um usuário isolado der nota 5.0 para um filme desconhecido, a média dele vai para o topo de forma injusta, criando anomalias (*outliers*) que prejudicam o cálculo de distância do K-Means.
- **Padronização Z-Score (StandardScaler):** Aplicamos essa transformação nas notas e nos votos. *Justificativa:* O volume de votos chega a milhares, enquanto as notas variam só de 0.5 a 5.0. Se jogássemos esses valores brutos no algoritmo, a distância dos votos esmagaria a das notas, tornando a avaliação do filme invisível para o modelo. A padronização deixa as duas variáveis com o mesmo peso.

Algoritmo escolhido e critério de definição do número de grupos

Rodamos o K-Means testando opções de 2 a 10 grupos. Para não travar o computador ao calcular a Silhueta na base inteira, usamos uma amostra segura de 5.000 registros.


Ao analisar os gráficos gerados, observamos um cenário interessante: o Coeficiente de Silhueta apresentou o seu pico máximo absoluto em $K = 4$ (0.536), seguido de $K = 3$ (0.527). No entanto, o gráfico do Método do Cotovelo revelou que a descida da curva de Inércia se estabiliza de forma acentuada logo após o 3. Como a diferença matemática no score de Silhueta entre os dois valores é irrelevante (apenas 0,009) e o "cotovelo" da Inércia apontou para o 3, adotamos estrategicamente $K = 3$. Essa decisão une a consistência estatística dos dois gráficos à busca por simplicidade, gerando uma divisão de catálogo muito mais limpa e interpretável para as regras.



Avaliação dos resultados obtidos

Ao rodar o modelo definitivo com 3 grupos e desfazer a padronização dos centróides (inverse_transform), conseguimos traçar o perfil exato do catálogo:

- **Cluster 0 (filmes de nicho / pouco votados):** Tem pouquíssimos votos e notas bem espalhadas. É a grande massa do catálogo, formada por filmes independentes, antigos ou desconhecidos do grande público.
- **Cluster 1 (filmes cult / aclamados):** Tem um volume médio/alto de votos e notas muito boas. É a prateleira dos filmes de prestígio, queridos pela crítica e por cinéfilos dedicados.
- **Cluster 2 (blockbusters de massa):** É o menor grupo em quantidade de filmes, mas tem um volume absurdo de votos. São os campeões de bilheteria, filmes super populares que quase todo mundo assiste e avalia.



Regras de Associação

Objetivo da análise

Aqui o foco mudou para o comportamento do usuário. Queríamos entender dois níveis de consumo: o micro (quais filmes específicos andam juntos) e o macro (como os gostos por gêneros se cruzam na cabeça das pessoas).

Dados utilizados e pré-processamento

Para as duas análises, aplicamos um filtro de corte bem severo: só consideramos avaliações com nota maior ou igual a 4.0. *Justificativa:* Precisávamos mapear o que o usuário realmente gostou (relevância de mercado), transformando notas contínuas em uma "cesta de compras" booleana (verdadeiro se gostou, falso se não assistiu ou não gostou).

- **Preparação por títulos (foco no produto):** Criar uma matriz com todos os filmes causaria um estouro de memória no computador. Por isso, filtramos o escopo mantendo apenas os 200 filmes mais curtidos da base. Agrupamos por usuário,

pivotamos a tabela e binarizamos tudo de forma direta e rápida usando o operador lógico (`matriz > 0`), resultando em uma matriz final de 283.514 usuários por 200 filmes.

- **Preparação por gêneros (foco no perfil):** Aqui processamos todos os 324.391 usuários da base. Para a memória aguentar, agrupamos os gêneros por usuário, limpamos o termo genérico (`no genres listed`) e usamos o método `.explode()` para abrir as listas de forma vetorizada. No fim, geramos uma matriz enxuta de 19 colunas puras (os gêneros reais da base), binarizada com o operador lógico (`matriz > 0`).

Algoritmo empregado e apresentação das principais regras

Usamos o algoritmo Apriori da biblioteca `mlxtend` e organizamos o ranking final de regras de forma decrescente pela coluna de confiança.

Principais regras por título (suporte maior ou igual a 0.15 | confiança maior ou igual a 0.50)

Os resultados mostraram que o algoritmo isolou perfeitamente o comportamento de maratona de franquias. Quem começa a assistir a uma sequência dificilmente para na metade. Um exemplo claro que saiu no topo dos nossos resultados foi:

- **Regra:** SE (The Lord of the Rings: The Two Towers) -> ENTÃO (The Lord of the Rings: The Fellowship of the Ring). Essa regra veio com um suporte alto, confiança superior a 85% e um Lift > 4.0, provando matematicamente o forte vínculo desse nicho de fãs.

Principais regras por gênero (suporte maior ou igual a 0.60 | confiança maior ou igual a 0.60)

Como os gêneros são muito comuns, o algoritmo encontrou inicialmente um total de 5.372 associações. Para refinar esse resultado, filtramos a base para exibir apenas regras puras (com 1 gênero por vez) e com Lift > 1.0, reduzindo o escopo para as 94 regras mais relevantes.

Desse grupo selecionado, o Top 10 trouxe duas grandes descobertas sobre o perfil dos usuários:

- **A força do gênero Drama:** Em 9 das 10 principais regras do ranking, o resultado final (consequente) foi o gênero Drama. A regra SE (War) -> ENTÃO (Drama), por exemplo, trouxe uma confiança impressionante de 99,8% (suporte: 0.637; lift: 1.045). Isso prova que quem consome gêneros mais específicos (como Guerra ou Histórico) quase inevitavelmente consome e gosta de dramas, mostrando que esse gênero é uma unanimidade na base.
- **A dupla perfeita:** A regra SE (Mystery) -> ENTÃO (Thriller) registrou suporte de 0.656, confiança de 0.981 e o maior Lift do nosso ranking (1.133). Isso indica uma preferência muito direcionada: quem gosta de tramas de Mistério tem uma inclinação real e exclusiva ao consumo de Suspense.

CONCLUSÃO

A modelagem descritiva funcionou perfeitamente. Conseguimos ver na prática que esses dois algoritmos resolvem problemas diferentes e se completam: o K-Means é ótimo para organizar a retaguarda da plataforma (dividindo e segmentando o portfólio de filmes do catálogo), enquanto o Apriori é o motor ideal para a linha de frente (disparando recomendações inteligentes na tela para o usuário).

Fazendo uma análise crítica do desenvolvimento, o limite de 200 filmes foi um passo obrigatório para não travar o hardware na associação por títulos. Em contrapartida, a nossa estratégia na modelagem por gêneros usando o método `.explode()`, contornou o volume gigante de mais de 324 mil usuários e condensou tudo em uma matriz leve de 19 colunas.

Os resultados que encontramos batem muito de perto com o que vemos no mercado de tecnologia atual e em artigos publicados pela Netflix ou pelo MovieLens. Estudos da área de sistemas de recomendação mostram que sugerir coisas baseando-se apenas em títulos sofre com o problema de "inicialização a frio" (*cold start*), que é quando um usuário acabou de criar a conta e a plataforma ainda não sabe o que ele curte. A descoberta de regras macros de gênero com confianças batendo em quase 99% valida o que as grandes plataformas fazem na prática: sugerir gêneros interligados e de apelo universal logo no cadastro do cliente, garantindo que ele ache algo de valor e continue engajado desde o primeiro clique.

REFERÊNCIAS

- GODOY, Angela Rosa Locateli de. **Mineração de Dados**. Rio Claro: FATEC, 2026.
- HARPER, F. Maxwell; KONSTAN, Joseph A. **The MovieLens Datasets: History and Context**. ACM Transactions on Interactive Intelligent Systems (TiiS), v. 5, n. 4, p. 1-19, 2015.